江华麒-CodeAgen游戏开发模型评测

2026-10-25 | UE5 Lyra 四模型报告 | 完整正文与附录

场景：交互与背包、连杀荣誉、场景效果。每题开发预算 45 分钟，三题合计 300 分。

模型	交互	荣誉	场景效果	合计 /300
GPT-6 Astra / high	67	77	73	217
Claude Opus 5.5 / high	64	77	74	215
GPT-5.6 Sol / high（请求）	9	59	61	129
DeepSeek	12	59	23	94

四组均为部分完成。已确认得分反映这次冻结交付的证据完成度，不代表模型普遍编程能力。未验证不等于失败。

GPT-5.6 使用荣誉标识符最小修复后的 129/300；原始 87/300 保留。未裁定部分分别标明候选前置、评测缺口、混合原因及归因不足。

正文：完成状态与优劣 / 排序与原因 / 后续评测调整
附录：80 项评分矩阵 / 未验证原因逐项说明

公开报告与材料

GitHub 仓库：https://github.com/faith30/ModelTest

报告目录：https://github.com/faith30/ModelTest/tree/main/Reports/LyraFeatureSuite/2026-10-25

案例任务正文：交互与背包 · 连杀荣誉 · 场景效果

三题链接指向冻结起点中的 TASK 正文。报告目录尚未收录含时限、隔离和统一环境要求的完整运行提示词。原始运行日志及完整验收附件由评测方本地留档，不随本报告提供。

本版用于 PDF 与 Git 发布，评分和归因沿用 r5。

整理日期：2026-10-25（Asia/Shanghai）。本版在荣誉修复后结果的基础上，突出说明未验证来自候选前置功能、评测缺口、混合原因还是归因不足；保留“具体场景-完成状态-排序原因-后续评测调整”的结构。此次未重新运行模型或测试，未修改分数及原有归因。

场景：为现有 UE5 Lyra 多人射击项目扩展玩法与反馈系统

选取的具体编程场景是：在已有 UE5 Lyra 工程中完成可保存、可运行、支持多人游戏的功能扩展。它同时涉及 C++、Gameplay Ability System、蓝图、UMG 界面、数据资源、动画通知、Niagara 和网络同步，要求模型把逻辑、资源引用与游戏入口接成完整功能。

同一项目场景拆为三个独立开发任务，每题预算 45 分钟、满分 100 分。各题从冻结起点开始，不要求上一题成功，三题合计满分 300：

任务	用户能实际使用的目标行为	主要验收内容
交互与背包	靠近物品出现提示，按 F 拾取，按 Tab 查看背包。	距离与遮挡、物品配置、多人争抢、归属隔离、重生和切图后的行为。
连杀荣誉	服务器识别连杀和连续击杀，在正确玩家 HUD 显示对应荣誉。	时间与数量阈值、消息定向、队列与替换、界面素材、异常恢复和生命周期清理。
场景效果	走路与落地根据地面材质播放对应声音和 Niagara。	Notify/Trace、上下文与库匹配、蓝图职责、保存资源、动画 Modifier、编辑器预览和多人行为。

实际使用流程包括：让模型在独立工作区开发并交付，冻结候选后另行验收；核对干净构建、原生资源读取、保存后新进程重开、正常输入和多人运行。评分来自这些证据，模型在最终答复中自称完成不直接得分。

比较采用同一冻结题集和原评分条目。GPT-5.6 沿用同一起点、提示词与素材，35 个关键引擎文件与原三模型统一验收基线一致。客户端版本、历史修复和恢复仍有差异，下文保留这些条件，不能把四轮称为所有环境完全相同。

1. 各模型的任务完成状态、具体表现与优劣

四个模型整体仍为部分完成。 本表使用 GPT-5.6 荣誉修复后的已确认结果，原始交付 87/300、荣誉 17/100 另行保留。

模型	整体状态	交互 /100	荣誉 /100	场景效果 /100	合计 /300
DeepSeek	部分完成	12	59	23	94
GPT-6 Astra / high	部分完成	67	77	73	217
Claude Opus 5.5 / high	部分完成	64	77	74	215
GPT-5.6 Sol / high（请求）	部分完成	9	59	61	129

未验证原因概览

本报告基于这次本机实际开发记录和独立验收结果。任务状态、已确认分数和未验证原因分别记录：**“模型交付的前置功能没有打通”和“评测没有取得足够证据”是两种不同情况。**

- **模型交付前置未打通：** 已有证据表明必要的功能、配置或资源缺失，使后续检查不能成立。例如没有一次有效拾取，便无法检验拾取成功后的竞争去重。这反映本次交付不足，但不证明尚未测到的去重算法本身错误。
- **评测未形成有效观察：** 测试没有形成所需动作、时序或可靠取证，例如未能证明对象真正回收，或未建立受控的异步完成顺序。这是现有评测证据的缺口，不能据此判候选通过，也不能判候选失败。

- **混合原因与归因不足：** 前者同时存在候选前置和评测缺口；后者缺少足够证据确定责任。两类均单列，不强行塞入前两类，也不按比例拆分分值。

下表单位是原评分项的**权重（分）**，不是错误数量或测试次数。“未裁定合计”包含原状态中的未验证和基础设施阻断；它与原因分类是两个维度，**不是新增失败分**。

模型	未裁定权重合计	模型交付前置未打通	评测未形成有效观察	混合原因	归因不足
DeepSeek	69	26	21	17	5
GPT-6 Astra	42	0	37	0	5
Claude Opus 5.5	53	7	46	0	0
GPT-5.6 Sol（荣誉修复后）	81	55	17	7	2

“评测缺口”包括场景、时序和观测不足，不仅指工具报错。某模型这一列为 0，也只说明当前未知项中没有被归到该原因，不能理解为模型没有缺陷。逐项原因和原始证据保留在第 1.6 节及附录 B。

1.1 DeepSeek：部分完成，基础规则有效，完整交付较弱

交互：12/100，部分完成，核心闭环失败

已完成： 保留原有移动、视角和武器行为；事件补充数据能够进入能力；交付蓝图编译、新进程资源回读及部分说明边界有通过证据。

主要失败：

- 从保存的测试地图进入后，真实移动和 F 操作能进入生产拾取路径，但背包对象为 None；Tab 能触发能力，未出现实际背包界面。
- 目标失去资格后，交互提示跨多个扫描周期仍未清理。
- Actor/ActorComponent 接收和目标 ASC 路径没有完成所要求的完整交互；无效组件仍触发接收者，空接口场景出现实际崩溃。
- 物品配置、持久化输入及 UI 资源链存在缺失；动态调整物品配置不能得到要求的实际结果。
- 多人竞争中的必要成功产出、Pawn 更换后的后续交互未通过。

未验证边界： 拾取和 UI 主路径不成立后，部分界面、胜者归属及后续隔离断言无法获得完整证据；这些项目保留未验证。

连杀荣誉：59/100，部分完成，也是该组最强项

已完成： 服务器基础规则，包括连续击杀时间边界、存活连杀阈值、死亡/自杀/无攻击者重置、不同玩家独立计数；数据与蓝图资源；Elimination 和 Control Points 的实际链路；部分高档替换及公共对局回归。

主要失败：

- Dedicated、Listen 和本地多玩家接收隔离出现递归转发或重复通知，部分通知进入错误视图。
- 合法本地通知重放产生重复展示，无关 PlayerState 的过滤不足。该证据没有证明客户端能伪造服务器击杀或突破服务器奖励权限。
- 异常媒体资源后的恢复、HUD 清理和实际 UI 媒体表现未通过；重生或进入新世界后仍看到旧荣誉提示。
- 设计说明和可复现证据文档未满足要求。

未验证边界： 异步加载完成顺序与队列展示顺序仍有 4 分未验证。

场景效果：23/100，部分完成，代码、资源与效果不一致

已完成： 部分资源库和上下文切换、角色隔离；蓝图编译；默认库有效条目、项目物理表面映射；工厂创建和新进程回读。

主要失败：

- 存在专用组件时，通用接口接收者被跳过；有效物理命中和表面转换条件下缺少要求的输出。
- 上下文匹配把父标签当作精确匹配，多条命中累加和重复加载处理不符合要求。
- 保存的 B_FootStep 分支执行线断开，下游节点不可达；命中位置和法线没有正确连接，生成位置保留默认值。
- Walk/Land 的保存标签与实际应用结果不符；第二次 Apply 后有效 ContextFX Notify 从 2 个变成 3 个，新增结果在重新打开后仍存在。
- 第二资源库虽然存在有效条目，保存的第二角色仍引用默认库；测试地面物理材质及验证资源不完整。
- 编辑器预览未得到要求的正向声效/特效；部分“已保存、已回读”的交付说明与资源实际状态不符。

评价： 本次 DeepSeek 能实现部分局部规则与数据结构，但“配置已保存-正常操作触发-运行结果正确”这一整条链路完成度不足。低分有大量已确认候选缺陷支撑，不能全部归因于评测环境；剩余 69 分未知仍需独立保留。

未验证归因： 69 分未裁定中，26 分由候选前置功能阻断，21 分是评测覆盖或取证缺口，17 分原因混合，5 分暂不能明确归因。候选前置的具体例子是生产拾取得到 Inventory=None、没有成功拾取正例，使成功后的去重和复制检查无法成立。因此，既不能把这 69 分都归给评测，也不能全部当作已确认算法错误。

1.2 GPT-6 Astra：部分完成，已确认完成度和覆盖率最高

交互：67/100，部分完成

已完成： 多客户端竞争同一物品、重复请求去重、场景状态同步、背包归属隔离；遮挡和超距拒绝、提示清理、无效目标安全处理；实时背包更新、重复打开无重复广播，以及持久化资源和蓝图回读。

主要失败：

- 有效近距离目标在部分条件下没有出现提示。
- 完整 ActorComponent 接收路径及目标 ASC 路径未通过。
- 合法 StackCount=3 变体没有得到物品；名称/图标及物品定义变更已有成功证据，失败不能概括成所有配置变更都无效。
- 背包名称和数量布局重叠，影响查看和重新打开后的呈现；该现象不等于背包重复生成物品。
- 更换 Pawn 后交互失效；关键生产失败路径的诊断日志不足。

未验证边界： 交互进行中销毁目标的精确动作时序没有形成，保留 3 分未验证。

连杀荣誉：77/100，部分完成

已完成： 基础规则、Dedicated/Listen/本地多玩家隔离、数据和 Toast 资源、两种真实对局模式、无效资源后的恢复、文档及公共回归。

主要失败： 通知重放产生重复展示；Relay/Host 蓝图主要作为薄转发层，将职责转入 C++，不满足任务明确要求的实质蓝图实现。

未验证边界： 高低档替换、异步顺序、生命周期清理仍有 13 分未验证；UI 媒体整体判定另有 3 分受取证基础设施影响。实际图标和音频已有正向证据，但截图/Slate 额外推进影响精确显示时长测量，不能判为该项完整通过，也不能直接判模型时长实现失败。

场景效果：73/100，部分完成

已完成： 核心 Notify、Trace、精确上下文匹配、多条资源命中、加载和负向路径；双角色隔离；专用服务器无输出、客户端只输出一次；实质 FootStep 蓝图、地图/资源库/工厂配置；重复 Apply 后两个有效 Notify 的字段、数量和重新打开结果保持稳定。

主要失败： 保存的 Land 效果配置为 Walk，实际 Apply 也生成 Walk，属于候选配置错误。

未验证边界： 完整参数视听效果、原类型兼容、可见脚部位置/法线仍未验证。编辑器预览有正向证据，但配套游戏隔离试验没有形成正常 Hero 前后对照，因此不能判“预览无污染”通过，也不能反向认定已污染游戏。

评价： GPT-6 在这批交付中取得最高的已确认分数和覆盖率，多人交互、失效处理和场景效果主链路较完整。但仍不能直接交付为全功能完成，尤其要补配置变更、UI 排版、蓝图职责和 Pawn 生命周期。

未验证归因： 42 分未裁定中，37 分属于评测前提或观察不足，另有 5 分涉及选图等责任尚未厘清，保留归因不足。当前没有未知项被归为纯候选前置阻断，但这不等于没有模型缺陷：已确认失败的 41 分单独记录，不混入未知。

1.3 Claude Opus 5.5：部分完成，蓝图职责和部分编辑器流程较好

交互：64/100，部分完成

已完成： Actor 和 ActorComponent 两类目标均有实际完整拾取证据；多人竞争、请求去重、归属隔离、遮挡和超距拒绝，以及持久化配置、蓝图和诊断信息。

主要失败：

- 目标 ASC 路径将物品交给目标所有者，归属不符合要求。
- 空接口场景出现实际崩溃。
- Tab 无法正常关闭界面并恢复输入焦点。
- 更换 Pawn 后仍沿用旧 Pawn 的扫描任务。

未验证边界： 三种配置变更的实际拾取均成功，但 Tooltip 没有触发或采集到所需 UI 名称证据，配置项因而未能完整裁定；另有界面和动作条件未形成的缺口。合计保留 24 分未验证，不能将这些缺口当作通过，也不能把所有缺口都归因于界面无法关闭。

连杀荣誉：77/100，部分完成

已完成： 基础规则、网络分发、真实对局链路、数据资源和文档回归；Relay 的本地/远端分支以及 Host 的创建、播放和移除承担实质蓝图职责。

主要失败： 通知重放重复展示；高档替换时 Double 与 Triple 重叠；异常媒体资源后的合法后续流程出现崩溃；正常重生且新 Pawn 已就绪后，旧 Toast 仍显示。

未验证边界： 异步队列及完整 UI 媒体行为共 7 分受基础设施影响。录到的 MetaSound 音频没有充分证明来自指定资源，不能据此声称“声音正确”，也不能写成“静音”或“播错声音”。

场景效果：74/100，部分完成

已完成： 核心匹配与资源主链路、保存的地图及第二资源库、实质蓝图和工厂；编辑器预览能按库、上下文、表面切换，并形成正常 Hero 前后游戏隔离的有效对照。

主要失败： Modifier 保存与应用的 Walk/Land 配置错误：Walk 生成 Land，Land 的原 2 个有效 Notify 变成 0 个。

未验证边界： Walk 的重复应用有非零稳定结果，但 Land 的 0→0 只能说明空结果没变化，不能证明有效 Notify 的重复 Apply 正确，因此完整幂等性仍未验证。完整参数视听、原类型兼容及脚部位置/法线同样存在缺口。

评价： Opus 的本次交付在部分实质蓝图和编辑器预览环节更完整，与 GPT-6 属于接近的完成度。它仍存在崩溃、输入焦点、荣誉清理和动画配置问题，不能把较少的确认失败权重直接解释为总体更可靠。

未验证归因： 53 分未裁定中，7 分是候选前置未打通，46 分是评测缺口。前者包括界面无法完成正常关闭与重开周期，及 Land 首次生成零个有效 Notify，使后续完整幂等性缺少非空基准；后者包括已拾取成功却未采到 Tooltip 名称、异步或视听取证不足。没有证据的部分仍不判成功或失败。

1.4 GPT-5.6 Sol：原始交付与荣誉最小修复后的结果

原始荣誉正常 Unity 构建失败的记录保留。经用户授权，助手仅在独立副本中修改两个 C++ 文件内四处 GameplayTag 标识符；没有修改标签字符串、业务逻辑、蓝图资产或构建配置。下列荣誉分数来自修复后的独立验收，交互与场景效果原样保留。

交互与背包：9/100；确认失败 39，未验证 52

已完成： 原生组件负向安全处理、补充事件数据以及部分说明与边界记录有通过证据。

主要失败： 保存交付未完成 F/Tab、AbilitySet、物品模板和 UI 的持久接入。正常输入已到达 viewport/PlayerInput，目标在扫描范围内且独立碰撞命中，但没有形成生产能力、提示、拾取和背包闭环；死亡/更换 Pawn 后的后续交互也没有成立。

未验证边界： 缺少有效拾取正例时，不能把零库存、零提示或零成功次数当成遮挡拒绝、竞争去重及归属隔离通过。辅助 C++ 组件测试成功也不能替代正常 F 操作的生产接线。52 分未知保留。

连杀荣誉：59/100（标识符修复后）

本轮确认得分 **59/100**；四状态权重为通过 59、确认失败 28、未验证 13、基础设施阻断 0，合计 100。状态权重不是独立缺陷数量。原 24 个评分项分别为 13 通过、8 失败、3 未验证、0 基础设施阻断；58 个较细变体分别为 20、20、17、1，变体数量不用于折算得分。

已完成： 两文件四处标识符修复后，正常 Unity 干净构建通过。原生处理器探针验证相邻击杀时间边界、5/10/15/20 阈值和玩家隔离，真实死亡、自杀及环境伤害场景补证重置；没有把所有更宽的自然对局变体都写成通过。Dedicated/Listen 的原窄口径定向接收有正向证据。两次独立新进程读取核验保存资源，六个蓝图在当前模块上编译成功；七行数据、Registry、持久布局及文档原评分项通过。显示中的低档替换，以及待显示奖励经过 GC 后仍能显示，均有局部正例，但没有据此授予整个异步队列项通过。

确认失败： 本地分屏奖励控件覆盖了另一玩家视图；本地消息总线伪造探针产生额外提示（不是客户端伪造服务器击杀的证明）。Relay 保存图缺少所要求的实质业务连线。实际对局已有伤害、击杀、奖励和动态 Toast，但呈现为大面积白色遮挡、拉长图标及不可读名称，Elimination、Control Points 和媒体完整性因此失败。缺图标/错误声音时未形成可读文字回退；NaN 输入链缺少可定位诊断，其是否永久占位仍未验证。重生后的旧提示继续显示，且上一生命中排队的奖励随后出现，清理项失败。该生命周期探针沿用原 054 的配置，将七行显示时长临时设为 12 秒以形成重叠；这是该条件下跨真实重生的反例，与默认 2.25 秒的计时观察分开。正常奖励约 2.25 秒的控件移除和部分音源支持证据保留，不等同完整视听效果通过。

公共回归通过原项 5.3： Elimination 已实际完成 10 次击杀及助攻、双客户端公共播报、可读计分板；第二次武器补充未完成，30 分结算的宽变体保留未验证。Control Points 则完整完成三次实际占点、队伍到 150 分、可读胜利结算及下一局等待。按旧 GPT-6、Opus 的同一原项口径，完整 Control Points 流程与独立 Elimination 前缀共同支持 5.3；未宣称两个宽变体都通过，也没有套用公共玩法破坏封顶。

仍未裁定的原评分项：

- 1.5（4 分）：缺档无替代/不重复、真实离场和新玩家独立计数均有正例；原观察器weak.IsValid在GC前已false，未测到对象实际回收，不能仅TObjectPtr/gc0认定泄漏，原整项记录可释放仍未验证。
- 4.1（5 分）：显示态替换已成立，但等待态安全地面/低请求、高Row取消及晚回调必要链没有形成；串行实现和未提供独立退出窗口不构成已确证的原项功能缺失。

- 4.2（4 分）：实际非空FIFO与GC存活有正例；受控逆序及两个实际候选callback身份/时序没有闭合。未用旧私有字段形状要求或必须并行加载的新条件判失败。

69 项正式作业均已结束，含原失败和超时记录；这不表示 69 项全部通过。四连杀媒体场景因实际击杀间隔超过窗口而未形成前提。切图变体第二次确已加载新世界，但观察器使用的可复用世界编号发生重复，最终达到原 900 秒时限，归为基础设施阻断；原项 4.4 仍由另一重生场景的真实反例判失败。另一个菜单退出变体已创建菜单，但点击前提未形成，没有完成退出和重进。文档中的历史 Adaptive 构建和资源检查有真实记录，未冒充本轮正常 Unity 或完整运行验收；部分描述过宽的行为保证在更细的文档变体中另行反映。

场景效果：61/100；确认失败 23，未验证 16

已完成： Trace、精确资源匹配、多条命中、错误资源恢复、两角色组件级隔离及上下文切换；保存库的音源差异、物理表面映射、工厂、公开类型兼容、蓝图编译、文档；重复 Apply 的非空结果稳定性以及原窄口径的编辑器预览/注册隔离。

主要失败： Notify 到 Actor 接口后跳过接口组件；FootStep 和验证蓝图缺少所需生产分支与 Niagara 接线；第二库未被验证角色实际引用；保存地面没有形成所声明的 Concrete/Glass 物理表面；Modifier 继承空的原生 OnApply，未按输入生成或更新 Notify。真实默认表面 Walk/Land 已触发，但未得到候选所属脚步输出，六组合门禁为失败。

边界： 重复 Apply 稳定不等于正确生成；音源配置有效不等于六组合视听全部通过。窄评分项 5.6 的预览注册隔离通过，但四个范围更广的预览变体仍未验证。参数效果、完整生命周期、网络双重转发抑制及死亡/重生回归共 16 分未知保留。

评价： GPT-5.6 原始交付为 87/300，接受同类最小标识符修复后为 129/300，仍属部分完成。新增的是修复后运行证据，没有再次调用模型开发；交互 9 分和场景效果 61 分保持原样。原始构建缺陷保留，不能把修复后的通过写成模型首次交付即可构建成功。总未知权重由 147 变为 81，其余未裁定项不能自动算成通过或实现错误。

GPT-5.6 的 81 分未裁定具体来自哪里：

- **55 分由模型交付的前置功能或资源未做通而阻断。** 其中交互 47 分、场景效果 8 分。例如输入、能力、物品模板和背包界面未形成有效拾取正例，挡住了竞争去重与实时刷新验证；缺少所需物理地面或有效客户端效果，也挡住参数和网络去重检查。这说明前置交付不足，尚不能证明下游算法错误。
- **17 分属于评测缺口。** 荣誉 13 分分别是对象实际回收未被观测到（4 分）、等待态替换链未形成（5 分）、受控异步回调顺序未闭合（4 分）；另有场景效果死亡/重生回归的 4 分，评测未建立合法敌对目标，缺少必要动作覆盖。已有局部正例保留，但不足以使完整评分项通过。
- **7 分是混合原因。** 交互中销毁目标的 3 分，同时缺少候选有效交互正例和准确动作时序；场景效果生命周期的 4 分，同时存在候选非空输出不足与测试装置未完成有效销毁对照。两类影响不能凭现有证据拆成精确分值。
- **2 分暂不归给任何一方。** 公共操作回归已有成功观察，但 GPT-5.6 与旧三组对“是否必须先开关背包”的解释存在差异，属于判定口径待复核，保留归因不足。

修复前荣誉的 79 分未知属于历史分支；修复后当前荣誉只剩 13 分未知，且全部是评测缺口。不能继续把这 13 分归为原构建失败，也不能把当前总计 81 分全部说成评测没有测到。 此次只把原因说明写清，评分、原状态和已有归因标注均不变。

1.5 原始结果、未验证项与干预边界

评估分支	交互	荣誉	场景效果	合计
GPT-5.6 原始交付	9	17	61	87
GPT-5.6 荣誉标识符修复后	9	59	61	129

模型	通过权重	确认失败权重	未验证权重	基础设施阻断权重	已裁定覆盖率
DeepSeek	94	137	56	13	77.0%
GPT-6 Astra / high	217	41	31	11	86.0%
Claude Opus 5.5 / high	215	32	38	15	82.3%
GPT-5.6 Sol / high（请求）	129	90	81	0	73.0%

四种状态每行合计 300；覆盖率为（通过 + 确认失败）÷300，不是通过率。not_run 包含已执行但必要前提或观察条件未形成的情况，未知没有自动算成通过或失败。

旧 DeepSeek 荣誉为三文件八处标识符修复，GPT-6 为两文件四处；本轮 GPT-5.6 采用同类两文件四处最小修复。原始不可构建事实与人工干预量分别保留，不能称为原始交付首次构建成功。客户端、历史过程和尚未验证范围仍须分别说明。

本轮沿用原 v2 题集、24 个荣誉评分项和 58 个变体位置，以及原 69 项正式作业、场景参数和超时。当前 36 个关键引擎文件均核验，历史三模型对应的 35 个重叠文件一致；正常 Unity 构建、实际进程与模块身份、源文件和资源字节均留有检查。不能由这些核验声称全部历史环境逐比特相同：GPT-6/GPT-5.6 的 Claude Code 版本为 2.1.289，DeepSeek/Opus 历史记录为 2.1.295。实际输入证据是进程内 Slate/PlayerInput，不代表 OS 硬件键盘测试。

原资格检查 02 的文件读取 PermissionError 保留，额外执行了唯一一次已封存的同脚本、同计划恢复；除标签外参数未变，原尝试未删除。正式 039 的合法奖励前提未形成及 055 的观察器世界编号复用超时各自保留，没有据退出码自动判业务失败。064 公共回归停在第二次武器补充，客户端断线后按原观察期限正常退出，整项作业约 950.5 秒且没有外层超时；它的局部正例与未完成结算分别记录。四状态权重按完整评分项记录，某个变体的基础设施阻断不推翻同项已有真实反例。

实际 GPT-5.6 Sol 路由在原开发轮已核实；high 保留为客户端请求，上游实际思考预算未直接观察。原模型开发时间、转换器中断和中性继续消息等过程仍见原始报告，本轮没有增加模型开发回合。

音频取证包含实际声音实例与冻结 PCM 的部分来源支持，未进行人耳试听，也未证明全混音中只播放一次。控件的渲染资格时长不能代替可读画面或入场、离场动画的观察。

下一轮统一修订评测时，应使用按加载代次分配的世界标识，补齐候选请求、取消与回调的身份链，以及实际对象回收见证；修订后对所有受影响模型按同范围重跑。上述建议不会反向增加本轮要求，也不会把现有未知补成通过。

1.6 未验证原因的区分

交互与背包的差距有已确认的交付缺陷支撑，同时存在由这些缺陷挡住的下游验证和评测本身未形成的观察。
DeepSeek 的拾取已进入生产逻辑却得到 Inventory=None，Tab 能触发能力却未显示背包；GPT-5.6 的保存交付缺少输入、能力授予、物品模板及 UI 的完整接入。GPT-6 与 Opus 已有核心拾取和多人流程正例。因此，本轮可用性差距成立，但不能把 DeepSeek 的 88 分、5.6 的 91 分未得分全部写成已证实的算法错误。

原因标签解释的是“为什么这一原评分项尚未裁定”，与通过、失败、未验证、基础设施阻断这四种原状态分开。**候选前置**指有证据表明已交付功能、资源或构建条件缺失，导致下游检查不能成立；**评测缺口**指测试没有形成所需动作、时序、对照或可靠观测；**混合原因**指两类缺口同时存在，现有证据不能拆分其影响；**归因不足**指缺少足够证据确定是哪一方造成。评测缺口也包括取证或覆盖不足，不限于工具报错。

原因按完整评分项标注；同一前置错误可能影响多项，所以表中权重不是独立错误数量。混合项不再拆成虚假的精确分值。“候选前置”只定位当前验证被什么挡住，不证明下游算法错误，也不意味着必须修改候选才能设计独立补测；“评测缺口”同样不证明候选通过。

交互与背包的失败与未知

模型	通过	确认失败	未知合计	候选前置	评测缺口	混合原因	归因不足
DeepSeek	12	49	39	23	3	13	0
GPT-6 Astra	67	30	3	0	3	0	0
Opus 5.5	64	12	24	3	21	0	0
GPT-5.6 Sol	9	39	52	47	0	3	2

例如，始终无法成功拾取，便无法判断重复请求是否会重复加物品；这属于下游未验证。反过来，F 只排队、能力尚未执行就销毁目标，不能验证“交互执行中销毁”；这是测试时序没有形成。Opus 的配置变更已有实际拾取正例，但 Tooltip 名称未触发或采集，属于评测观察缺口，不能写成配置功能失败。

公共操作回归 1.2 的口径待复核： GPT-5.6 已有两地图移动、视角、武器和标记等成功观察，但原裁定因未先开关背包而保留整项 2 分未验证；旧三组的裁定说明明确允许独立公共操作正例，不要求先成功开关背包。这是原评分项与更宽测试变体的解释可能不一致。此处保留原分数，将原因列为“归因不足”，不把这 2 分计入确定的候选前置问题，也不断言必须先修背包才能裁定。

输入证据层次： GPT-5.6 的输入证据来自进程内 Slate 至 viewport/PlayerInput 的路径；没有完成 OS 或硬件键盘输入验收。报告中的输入到达和业务未响应不应扩大成人工键盘操作已验证。

三项任务的未知原因权重（荣誉修复后）

模型	任务	未知合计	候选前置	评测缺口	混合原因	归因不足
DeepSeek	interaction	39	23	3	13	0
DeepSeek	accolades	4	0	4	0	0
DeepSeek	context-effects	26	3	14	4	5
DeepSeek合计	三项任务	69	26	21	17	5
GPT-6 Astra / high	interaction	3	0	3	0	0
GPT-6 Astra / high	accolades	16	0	16	0	0
GPT-6 Astra / high	context-effects	23	0	18	0	5
GPT-6 Astra / high合计	三项任务	42	0	37	0	5
Claude Opus 5.5 / high	interaction	24	3	21	0	0
Claude Opus 5.5 / high	accolades	7	0	7	0	0
Claude Opus 5.5 / high	context-effects	22	4	18	0	0
Claude Opus 5.5 / high合计	三项任务	53	7	46	0	0
GPT-5.6 Sol / high（请求）	interaction	52	47	0	3	2
GPT-5.6 Sol / high（请求）	accolades	13	0	13	0	0
GPT-5.6 Sol / high（请求）	context-effects	16	8	4	4	0
GPT-5.6 Sol / high（请求）合计	三项任务	81	55	17	7	2

GPT-5.6 原始荣誉 79 分未知、原始总计 147 分未知及其原因记录仍完整保留在历史分支。本表只纳入修复后新评分中仍未裁定的项目；不能继续把这些项目一律归为原构建失败，也不能因构建修复成功自动判定下游行为通过。

2. 明确的性能排序及排序原因

这里的性能指原冻结评分标准下已确认完成的功能权重，不表示模型响应速度、价格或普遍编程能力。

排序	模型	确认分数 /300	交互 / 荣誉 / 场景效果
1	GPT-6 Astra / high	217	67 / 77 / 73
2	Claude Opus 5.5 / high	215	64 / 77 / 74
3	GPT-5.6 Sol / high（请求）	129	9 / 59 / 61
4	DeepSeek	94	12 / 59 / 23

按本批已确认得分排序为：GPT-6 Astra / high（217） > Claude Opus 5.5 / high（215） > GPT-5.6 Sol / high（请求）（129） > DeepSeek（94）。GPT-5.6 的新增得分来自先前被构建阻断、现有运行证据支持的原评分项；交互与场景效果没有重新评分。GPT-6 与 Opus 在交互及荣誉上的已确认完成度仍更高，GPT-5.6 与 DeepSeek 的比较需结合三项任务分别看，尤其是场景效果 61 对 23 分和交互 9 对 12 分。该排序描述单次冻结交付的证据完成度，不能外推为模型普遍编程能力或速度排名。 GPT-5.6 与 DeepSeek 的荣誉总分同为 59，但通过和失败的子项不同，同分不表示实现质量或缺陷相同。

GPT-6 与 Opus 的原结果仍分别为 217、215，只相差 2 分；其原模型对象和所有评分条目未改。单次交付及未验证范围不足以确立稳定总体能力顺序，ranking_final=false 保留。

3. 如果模型变强，如何调整这一场景的评测

当前四组仍未完整通过，下一步应先让现有缺口能够被可靠裁定。当更强模型逐渐通过基础功能后，再用预先冻结的新版本检验更复杂的配置、并发和维护能力。

3.1 先统一比较条件并补齐测量

- 按未验证原因安排补测：候选前置未打通时保留交付不足，辅助夹具测试下游须单独标明范围；纯评测缺口先完善动作与取证，再对受影响模型统一补跑；混合原因先建立独立有效对照；归因不足先补责任证据。不能用补测设计替模型补业务，也不能把未知直接折算成失败。
- 固定同一客户端、代理、引擎和评测器版本；提前声明原始交付与最小修复后的结果是否分开统计，对四组执行相同政策。
- 正常输入后等待可观察的动作回执和状态条件，再开始计量；每条案例独立准备和复位，避免前一条失败造成后一条无法测。准备过程不能替候选补缺失业务。
- 截图与音频采样不额外推进业务 Tick；统一游戏、UI 和单调时钟，减少采样对显示时长的干扰。
- 用正常死亡、销毁、重生和切图验证生命周期，并记录旧/新对象和世界身份。未销毁旧 Pawn 的测试装置不能被误判成候选缓存泄漏。
- 完整采集 Walk/Land×三种物理表面的连续画面与可归属音频，分别判断资源正确、参数生效和实际视听表现。

3.2 在同一项目场景中增加更难的任务与隐藏变体

增强方向	具体测试	要区分的能力
隐藏配置	运行前随机选取冻结种子：物品数量、图标、角色身份、库顺序、物理材质与时间阈值。	真正的数据与配置驱动，而非只对样例写死。
并发与异步	两玩家同帧争抢；相邻帧重复请求；异步加载乱序完成；荣誉高低档在同窗口到达。	服务器权威、去重、隔离、消息顺序和替换正确性。
故障与恢复	等待期间销毁目标、撤销能力、丢失资源、卸载 Experience；恢复后继续正常操作。	失败可诊断、不会阻塞后续，也没有旧回调或残留界面。
长时间运行	预先冻结 N 轮背包开关、重生、切图及 Modifier Apply；每轮比较注册数和资源状态。	持续有效的非空结果与状态清理，防止用始终无输出掩盖问题。
维护与改需求	在已完成交付上添加一种表面、一个物品配置或新的荣誉阈值，再运行原回归集。	可读性、职责划分、配置扩展和避免回归的能力。
完整资源闭环	保存并关闭编辑器，在全新进程中重开，再用正常输入完成真实对局。	代码、蓝图、资源引用和运行行为的一致交付。

新增参数用例应先有有效的正常输出作对照，再改变单一输入观察预期变化。测试功能可以独立准备；长生命周期作为单独完整案例执行，保持其他案例不依赖它成功。

3.3 从一次交付对比升级为可重复的模型评测

- 每模型每任务进行至少 3-5 次独立生成，固定预算、起点与提示，保留全部结果；将生成成功率和同一交付的重复运行稳定性分开。
- 单列原始交付首次构建/任务通过率、最小修复后结果、各维度得分和人工介入量；样本足够时报告离散程度及置信区间。
- 开发时间、工具与构建时间、网络/代理等待、令牌和计费分别记录，再比较效率。
- 保留当前 v2 作固定回归集；新增难题使用另一个冻结版本。先确定案例、权重和裁定规则，再运行更强模型，不按看到的结果调整分数或排序。

附录：结果来源与复核

本版仍为每模型 80 个评分项、184 个变体位置，共 320 项裁定与 736 个变体位置。旧三模型五条不适用结论保持原样；GPT-5.6 的原荣誉 58 条另保留在 raw_arm，本表只计一次修复后分支。

- 本版四模型 comparison.json
- 本轮荣誉最终审阅（本机留档说明）
- 原始四模型比较（本机留档说明）
- 上一版问答报告（本机留档说明）

附录 A：原 80 项评分矩阵

interaction

项目	检查	权重	DeepSeek	GPT-6 Astra / high	Claude Opus 5.5 / high	GPT-5.6 Sol / high（请求）
1.1	从 L_InventoryTestMap 自动进入完整交互流程，无控制台临时授予或补配置	3	失败	通过	通过	失败
1.2	移动、视角、武器、独立地图及标记操作保留	2	通过	通过	通过	未验证
2.1	靠近/远离范围及转开视线，提示与触发许可同步变化	5	未验证	失败	未验证	失败
2.2	遮挡、墙后及超距离请求均不能拾取	5	未验证	通过	通过	未验证
2.3	目标销毁/失去资格及时撤提示；快速状态变化不留旧目标	5	失败	通过	通过	未验证
3.1	Actor 与 ActorComponent 接收者均能完成有效交互	3	失败	失败	通过	失败
3.2	玩家授予能力与目标 ASC 有效句柄两种选项均工作	3	失败	失败	失败	失败
3.3	失效目标/句柄/组件安全失败	2	失败	通过	失败	通过
3.4	目标补充的事件数据实际到达接收能力	2	通过	通过	通过	通过
4.1	服务器与两个客户端竞争同一对象，只记一次成功	5	失败	通过	通过	未验证
4.2	快速重复 F 或重复请求不会重复加物品，仅获胜者获得物品	5	未验证	通过	通过	未验证
4.3	所有客户端场景状态一致，失败端不永久隐藏对象	5	未验证	通过	通过	未验证
5.1	原生读取至少两种有效定义、三个场景拾取配置及名称/图标/模板 StackCount=1；追踪实际使用引用	4	失败	通过	通过	失败
5.2	在评估副本修改一种配置后，拾取所得名称、图标、定义及数量随配置改变，无写死分支	6	失败	失败	未验证	未验证
6.1	拾取前后打开背包，已有和新增条目准确，无缺漏/重复	4	失败	失败	未验证	失败
6.2	保持背包打开时新增内容实时正确出现	3	未验证	通过	未验证	未验证
6.3	Tab 关闭/重新打开后内容正确且输入焦点恢复	3	失败	失败	失败	失败
7.1	两个客户端分别拾取，背包与提示均只属于各自玩家	5	未验证	通过	通过	未验证
7.2	重复打开界面不增加播报次数	3	未验证	通过	未验证	未验证
7.3	失败交互不出现成功提示	2	未验证	通过	通过	未验证
8.1	交互中销毁目标无残留 Indicator 或失效访问	3	未验证	未验证	未验证	未验证

项目	检查	权重	DeepSeek	GPT-6 Astra / high	Claude Opus 5.5 / high	GPT-5.6 Sol / high（请求）
8.2	死亡/重生与更换 Pawn 后计时器、监听、授予清理且后续交互正常	4	失败	失败	失败	失败
8.3	退出/重进地图不产生重复回调、提示或能力授予	3	未验证	通过	通过	未验证
9.1	全部交付/修改蓝图独立加载编译成功，不能只编原空壳	3	通过	通过	通过	失败
9.2	输入 F/Tab、AbilitySet、物品、各 UI 与 Experience 有完整持久配置和可达引用	5	失败	通过	通过	失败
9.3	保存交付后另起编辑器进程重读，引用和配置一致	2	通过	通过	通过	通过
10.1	模块分工和关键取舍清楚，测试步骤、实际结果和日志位置可复现	2	通过	通过	通过	通过
10.2	明确标注未执行的构建/蓝图/单机/多人检查	1	通过	通过	通过	通过
10.3	公共背包/武器无无关改动，关键失败日志可定位且非逐扫描刷屏	2	失败	失败	通过	失败

accolades

项目	检查	权重	DeepSeek	GPT-6 Astra / high	Claude Opus 5.5 / high	GPT-5.6 Sol / high（请求）
1.1	0/4/8/12 秒相邻击杀产生 2/3/4；4.5 包含，大于 4.5 重置	6	通过	通过	通过	通过
1.2	5/10/15/20 存活阈值各一次，死亡后重新计数	5	通过	通过	通过	通过
1.3	自杀不加分且重置；无攻击者死亡同样重置死者	5	通过	通过	通过	通过
1.4	A/B 交错击杀不串记录，两类可在同次击杀独立同时触发	5	通过	通过	通过	通过
1.5	未配置阈值无替代奖励，不重复发已达到阈值，玩家离开记录可释放	4	通过	通过	通过	未验证
2.1	专服+两个客户端：服务器判定，仅获奖者 HUD 收到一次，专服不生成 UI/音效	8	失败	通过	通过	通过
2.2	Listen Server 本地玩家与远端各能获奖，不重复、不串通知	6	失败	通过	通过	通过
2.3	本地多玩家视图按 PlayerState/LocalPlayer 正确隔离	3	失败	通过	通过	失败
2.4	客户端不能伪造奖励；重发/无关玩家消息不会重复通知	3	失败	失败	失败	失败
3.1	七行表的标签、名称、素材、位置、时长及替换关系语义正确，引用可加载	5	通过	通过	通过	通过
3.2	两处理器窗口/阈值映射与 Registry 行结构/数据源正确	3	通过	通过	通过	通过
3.3	Relay 图实际承担监听、定向及客户端衔接；Host 图实际创建/移除/呈现	4	通过	失败	通过	失败
3.4	Toast 实际文字/图标布局、音效引用及入场/离场实现持久落盘	3	通过	通过	通过	通过
3.5	交付蓝图在当前模块上独立编译成功；可打开且类型/路径兼容	3	通过	通过	通过	通过
3.6	Elimination 真实伤害/击杀至 HUD 的端到端链路工作	4	通过	通过	通过	失败
3.7	Control Points 同一注册链正常发奖，HUD/Experience 接入有效	3	通过	通过	通过	失败
4.1	同类高档替换正在显示/等待的低档，旧项不复活，单位置一次一项	5	通过	未验证	失败	未验证
4.2	不同类别按触发顺序展示，异步乱序完成不改变显示顺序	4	未验证	未验证	基础设施阻断	未验证
4.3	无效行/素材缺失/无效时长不堵后续，文字回退及低频诊断	4	失败	通过	失败	失败
4.4	HUD 重建/重生/切图/体验卸载清理回调、监听及旧提示	4	失败	未验证	失败	失败

项目	检查	权重	DeepSeek	GPT-6 Astra / high	Claude Opus 5.5 / high	GPT-5.6 Sol / high（请求）
4.5	名称/图标/声音/持续时间/显示位置在 HUD 中与资源一致，入场/离场可辨识	3	失败	基础设施阻断	基础设施阻断	失败
5.1	至少一页职责、服务端/客户端边界、消息/资源流及蓝图/C++ 分工	3	失败	通过	通过	通过
5.2	步骤与证据可复现，静态/资源/运行分开，未验证如实标注	3	失败	通过	通过	通过
5.3	比分/计分板、助攻、击杀播报与公共对局流程回归通过	4	通过	通过	通过	通过

context-effects

项目	检查	权重	DeepSeek	GPT-6 Astra / high	Claude Opus 5.5 / high	GPT-5.6 Sol / high（请求）
1.1	左/右脚及落地 Notify 正确到 Actor/接口组件，各有效接收者一次；空对象安全	5	失败	通过	通过	失败
1.2	Trace 通道/终点偏移/忽略拥有者/物理材质正确，无命中安全	5	基础设施阻断	通过	通过	通过
1.3	当前上下文与请求合并及表面映射影响实际选取，无重复转发播放	5	失败	通过	通过	通过
1.4	插槽/位置旋转/VFX 缩放/音量/音高确实改变结果	5	未验证	未验证	未验证	未验证
2.1	效果精确标签、请求精确包含全部条目上下文、空条目仅空请求：正反例均正确	5	失败	通过	通过	通过
2.2	多个匹配条目均贡献效果，无匹配清空输出	3	失败	通过	通过	通过
2.3	加载状态、坏软路径/错误类型不阻断其他资源，重复加载不累积	4	失败	通过	通过	通过
2.4	未映射表面/Trace 失败不保留上次标签，空配置安全	3	未验证	通过	通过	通过
3.1	两角色库/上下文隔离，替换/清空库立即生效，旧库不再播放	5	通过	通过	通过	通过
3.2	运行时上下文替换准确影响匹配，不污染另一角色	3	通过	通过	通过	通过
3.3	销毁/重生/重进关卡清除注册，无持续增长失效组件缓存	4	基础设施阻断	基础设施阻断	基础设施阻断	未验证
3.4	专服不生成声音/Niagara；客户端不因双重转发重复播放	3	失败	通过	通过	未验证
4.1	B_FootStep 图有实际分支/数据处理和接口链，使用命中位置/法线及左右脚，非全转给单一原生包装	4	失败	通过	通过	失败
4.2	B_FootStep、Modifier 及交付验证蓝图在当前 DLL 上无错误	3	通过	通过	通过	通过
4.3	公开变量/接口、原类及资源路径保持兼容，B_Hero_Default 引用有效	1	未验证	未验证	未验证	通过
4.4	B_FootStep 接口事件驱动可观察 Niagara，左右脚/命中法线实际生效	4	未验证	未验证	未验证	失败
4.5	Modifier 在两份验证动画生成/更新正确标签、插槽、Trace 参数的 ContextFX Notify	4	失败	失败	失败	失败
4.6	同一动画重复 Apply 后 Notify 数量/时间/参数稳定，无重复叠加	4	失败	通过	未验证	通过
5.1	默认库 Walk/Land×3 表面全部六组合有效，Concrete/Glass 音源有实际差异，至少一条 Niagara 可加载	4	通过	通过	通过	通过

项目	检查	权重	DeepSeek	GPT-6 Astra / high	Claude Opus 5.5 / high	GPT-5.6 Sol / high（请求）
5.2	第二库至少两条有效可区分数据，运行验证引用该库	2	失败	通过	通过	失败
5.3	Default/Concrete/Glass 项目表面映射正确持久保存	2	通过	通过	通过	通过
5.4	验证地图/交互蓝图/两种角色配置/三表面/Walk 与 Land 复制动画落盘且引用正确	4	失败	通过	通过	失败
5.5	现有 LyraEditor 工厂可实际新建/编辑有效库	3	通过	通过	通过	通过
5.6	动画编辑器库/上下文/物理表面预览有效且不污染运行注册	5	失败	未验证	通过	通过
6.1	设计、资源路径、逐项步骤、实际结果、日志/截图可复现	3	失败	通过	通过	通过
6.2	明确静态/构建/BP/运行边界，无无关资产批量改动或原实现恢复	3	通过	通过	通过	通过
6.3	正常角色移动、死亡/重生及无关武器反馈未受影响	4	基础设施阻断	基础设施阻断	基础设施阻断	未验证

附录 B：未验证原因逐项说明

DeepSeek

任务 / 项目	原状态	权重	原因分类	说明
interaction / 2.1	not_run	5	混合原因	背包未打开、合法点拾取未成功，候选前置缺失；同时出界变体实测仍在范围内，评测未采到触发许可分支。提示随视线变化已有证据，但完整许可同步无法裁定。
interaction / 2.2	not_run	5	混合原因	合法内点已进入 Collect，却因 Inventory=None 无法入库，缺少候选成功正控；评测又未形成精确等值、实际拒绝分支及正常移动后的旧提示竞态，不能归为单一原因。
interaction / 4.2	not_run	5	候选前置	双方重复 F 已送达，但服务器始终没有新增物品，独立单客户端拾取也失败。候选收集链缺少一次成功结果，因而无法检验成功后的去重和赢家归属；没有证实去重算法本身错误。
interaction / 4.3	not_run	5	候选前置	各端仍有目标、库存不变的状态已观察，但候选没有成功消耗物品的正例，无法判断拾取成功后的场景复制及失败端恢复。各端都没有变化不能证明同步正确。
interaction / 6.2	not_run	3	候选前置	Tab 与生产控件创建已记录，但背包未可见打开，拾取也未新增库存。缺少同一个已打开界面内的有效新增，无法检验实时监听；入口失败已有独立失败项，不重复判实时更新错误。
interaction / 7.1	not_run	5	候选前置	四个不同物品及顺序场景已运行，但候选没有各自成功入库、背包显示和成功提示的基线。无法检验玩家间归属隔离；全空结果不是隔离通过，也没有串端的直接反例。
interaction / 7.2	not_run	3	候选前置	Tab 请求实际成立，候选背包却未可见打开，也未形成一次成功播报。重复打开后的播报去重依赖这些前置，不能以始终零播报证明正确或认定重播算法失败。
interaction / 7.3	not_run	2	候选前置	失败端没有成功提示已有观察，但同场没有真实获胜者及成功提示正控，单人收集也失败。候选成功链未通使通知正反例无法对照；未发现失败端误报成功的直接反例。
interaction / 8.1	not_run	3	评测缺口	扫描后销毁、F 排队后而处理前销毁都观察到清理，但评测没有形成 Collect 已执行过程中才销毁目标的精确时序。已有证据不能代替原要求，也不能据此判候选残留或失效访问。
interaction / 8.3	not_run	3	混合原因	两轮真实旅行已清除旧世界，但候选初始成功拾取和 Toast 前置未形成；评测也缺少旧回调及能力授予逐身份退出的完整记录。重进后拾取仍失败不能扩展成旅行重复授予的结论。
accolades / 4.2	not_run	4	评测缺口	不同类别按实际触发顺序显示已有证据；候选采用同步查行及加载，没有生产异步完成回调。冻结证据计划要求的冷资源与真实 pending 反转未形成，属于评测场景适配缺口，不证明同步实现错误。
context-effects / 1.2	infrastructure_blocked	5	评测缺口	标准未明确偏移采用世界轴还是插槽轴；评测的竖直地面射线未证明候选旋转射线具备有效命中正控。六次调用均安全返回但全未命中，不能据此判 Trace 实现错误或完整通过。
context-effects / 1.4	not_run	5	归因不足	六组参数对照均执行，但缺少完整可归属声画对照；缩放试验选择了未配置 Niagara 的 Default，音高两次运行的动作姿态也不同。无输出与这些测量条件交织，现有证据不足以单独归因。
context-effects / 2.4	not_run	3	候选前置	已用独立物理查询确认有效命中及映射，再执行未映射、未命中和恢复序列，但候选初始正确选择始终未成功。因此无法验证成功之后的旧标签清除；恢复选取失败另归原 1.3 项。

任务 / 项目	原状态	权重	原因分类	说明
context-effects / 3.3	infrastructure_blocked	4	评测缺口	五轮真实切图清除了旧世界并保持一个有效注册；替换测试未销毁旧 Pawn，其注册增加不能视为泄漏。评测缺少有效敌对角色，正常战斗死亡及重生未形成，完整生命周期仍未验证。
context-effects / 4.3	not_run	1	评测缺口	当前类、接口参数、资源和 Hero 加载编译已有正向证据，但评测没有解码原基线全部公开变量的类型，也未证明其字节等价。只有名称和当前类型不足以完成兼容性对照，未发现不兼容反例。
context-effects / 4.4	not_run	4	混合原因	候选保存地图缺少 Concrete/Glass 地面，相关动作无法开始；已执行的 Default 动作又未证实 B_FootStep 接收调用及脚部特效。候选前置和运行取证均有缺口，不能把已确认的断线直接当成本项运行反例。
context-effects / 6.3	infrastructure_blocked	4	评测缺口	十二个生产移动、跳跃及射击窗口已记录正常移动、弹药减少和枪声音源，但评测缺少有效敌对角色，正常战斗死亡及重生未执行。公共回归的这一必要部分不能由替换 Pawn 或切图替代。

GPT-6 Astra / high

任务 / 项目	原状态	权重	原因分类	说明
interaction / 8.1	not_run	3	评测缺口	销毁发生在 F 已排队、Collect 尚未启动时，验证了处理前的安全性；评测未形成生产能力执行过程中再销毁目标的精确时序，无法判断原要求。
accolades / 4.1	not_run	5	评测缺口	正在显示的低档替换已有成功证据；等待队列试验停在安全落点前置，另一轮高档到达已太晚，未形成等待项及迟到回调的指定场景。
accolades / 4.2	not_run	4	评测缺口	真实跨类别触发顺序及等待期间 GC 分支已有证据，但评测没有形成冷加载后跨类别异步逆序完成，不能据正常完成顺序证明乱序仍正确。
accolades / 4.4	not_run	4	评测缺口	重生和切图各两轮已有清理及新奖励正例；菜单复测被 Online 前置与实际 Offline 界面不匹配阻断，待加载迟到回调、独立 HUD 重建等必要场景也未形成。
accolades / 4.5	infrastructure_blocked	3	评测缺口	名称、图标和部分声音来源已有正例；截图触发额外 Slate 推进并叠加采样滞后，无法可靠归因显示时长。四连杀刺激也超出时间窗，不能判候选时长实现错误。
context-effects / 1.4	not_run	5	评测缺口	十二次参数对照已执行并有实际对象及部分录音变化；图像不足以可靠对应粒子来源、位置和渲染年龄，音量及音高未完成听辨，完整视听对照仍缺证据。
context-effects / 3.3	infrastructure_blocked	4	评测缺口	五次世界重进的注册清理已有正例，但评测没有提供合法战斗对手，正常死亡重生未发生；替换 Pawn 保留旧对象，不能代替销毁与清理验证。
context-effects / 4.3	not_run	1	评测缺口	当前接口、资源路径及 Hero 引用已有证据，但读取工具未可靠解码原基线完整公开变量类型和标记，缺少兼容性对照；没有已确认的不兼容反例。
context-effects / 4.4	not_run	4	评测缺口	生产接口和资源链已执行，保存蓝图也有实质处理；现有画面无法可靠区分左右脚、命中法线及旧粒子残留，不能以组件字段代替可见效果验收。
context-effects / 5.6	not_run	5	归因不足	所选保存验证地图确为非 Lyra GameMode，未形成 Hero 前后对照；但候选声明它供按键驱动测试 Actor，原要求未限定正常游戏基线必须用此图。评测固定选图与候选配置的责任未能分清，不能据此称所有正常游戏入口缺失。
context-effects / 6.3	infrastructure_blocked	4	评测缺口	正常移动、跳跃落地和武器反馈已有实际正例；战斗测试未提供合法对手，死亡重生分支未执行，因此公共行为回归的完整合取要求仍未验证。

Claude Opus 5.5 / high

任务 / 项目	原状态	权重	原因分类	说明
interaction / 2.1	not_run	5	评测缺口	正常靠近及左右转向的提示同步已有正例；背包打开的远离变体中 S 未到达 PlayerInput，角色没有跨出范围。评测缺少有效远离动作，不能据持续提示判扫描错误。
interaction / 5.2	not_run	6	评测缺口	三种合法配置变体均真实拾取，图标、定义和数量变化已有证据；名称元数据也改变，但评测未触发或采集 Tooltip 的 UI 名称，完整呈现要求未验证。
interaction / 6.1	not_run	4	评测缺口	末态库存与图标对应已验证；计划未执行拾取前查看并关闭背包，空库存及不同新物品条件亦未完整形成，Tooltip 未采集。这些是该项动作与取证缺口。
interaction / 6.2	not_run	3	评测缺口	保持背包打开时 F 被 UI 接收，评测未造成真实库存新增；关闭背包后拾取再打开的正控成功。缺少同一打开实例的新增刺激，不能判实时监听算法失效。
interaction / 7.2	not_run	3	候选前置	成功拾取和提示已有正控，但候选 Tab 关闭及重开流程失败，后续输入一直留在已打开界面，无法形成重复打开周期；同实例未重播不能证明重开不重播。
interaction / 8.1	not_run	3	评测缺口	评测只在扫描后或 F 已排队而 Collect 尚未启动时销毁目标，未形成生产业务处理中的销毁时序；已观察的提前清理只能支持局部安全性。
accolades / 4.2	infrastructure_blocked	4	评测缺口	冷加载和跨类别逆序完成试验在任何击杀前就被测试装置的安全落点检查阻断；等待期间 GC 的成功分支不能代替指定逆序加载，队列算法仍未验证。
accolades / 4.5	infrastructure_blocked	3	评测缺口	六类荣誉的文字、图标和过渡画面已有证据；截图与 Slate 计时干扰未隔离，MetaSound 录音来源亦未充分归属，四连杀刺激超时。不能据此判静音或时长错误。
context-effects / 1.4	not_run	5	评测缺口	参数对照已执行且各组有实际音频输出，但所选 Default/Walk 场景没有 Niagara，无法观察缩放；相对旋转未直接采样，音量及音高缺实际听辨。场景和采集未覆盖完整参数效果。
context-effects / 3.3	infrastructure_blocked	4	评测缺口	五次世界重进显示有效注册清理；战斗测试没有合法对手，死亡重生未发生，替换 Pawn 又保留旧对象。评测未形成必要销毁场景，不能据此认定缓存泄漏。
context-effects / 4.3	not_run	1	评测缺口	当前接口、类和资源路径及 Hero 调用已有局部证据；原基线的完整公开变量类型未可靠解码，无法完成类型兼容对照，没有据此发现候选不兼容。
context-effects / 4.4	not_run	4	评测缺口	网络客户端的 Hero 接口、左右脚和命中字段及 Niagara 对象已有正例，但现有帧不能可靠辨认足印位置和命中法线表现，缺的是可见效果取证。
context-effects / 4.6	not_run	4	候选前置	Walk 的非空重复应用稳定已有正例；Land 因候选生成问题变成零 Notify，重复结果仅为零到零。缺少有效初次生成，无法验证两份动画的完整幂等性。
context-effects / 6.3	infrastructure_blocked	4	评测缺口	多次切图后的移动、跳跃落地和武器输入有正例；战斗测试未创建对手，正常死亡重生未发生，替换后部分动画与武器画面亦未采全，不能归为候选回归。

GPT-5.6 Sol / high（请求）

任务 / 项目	原状态	权重	原因分类	说明
interaction / 1.2	not_run	2	归因不足	两地图公共操作已成功；原裁定因背包未打开、第二变体前提未成立而保留未知，但旧三模型明确不要求先开关背包。该前提是否属于原项必要条件存在评分口径差异，暂不能单方归为候选或评测原因，待统一口径复核。
interaction / 2.2	not_run	5	候选前置	几何与输入操作已执行，但本用例没有成功的合法拾取正例，交互能力及保存模板缺失；因此零库存无法区分正常拒绝与功能根本未启动，遮挡和超距拒绝算法仍未验证。
interaction / 2.3	not_run	5	候选前置	目标失效场景已运行，但候选从未产生有效交互能力、选项或目标提示，也无稳定目标正例；没有可撤销的提示，无法验证失去资格后的清理，不能把始终不显示视为清理成功。
interaction / 4.1	not_run	5	候选前置	专服与客户端已完成输入、同步屏障和终态观察，单客户端正向对照也未成功拾取；候选缺少有效交互选项和物品模板，未形成真实竞争，零成功数不能验证只记一次成功。
interaction / 4.2	not_run	5	候选前置	重复请求与多人输入场景已执行，但候选缺少有效选项或可用模板，合法拾取正例未建立；因此没有新增物品不能证明去重正确，也无法裁定只有胜者获得物品。
interaction / 4.3	not_run	5	候选前置	网络角色完成了场景与终态观察，但候选未产生有效拾取及其状态变化；初始步枪复制仅是基线，不能替代拾取后的场景同步证据，失败端恢复显示的行为仍未验证。
interaction / 5.2	not_run	6	候选前置	名称图标、定义和数量三种变体均执行了输入，但候选保存的物品模板为空，使配置准备返回失败；未形成修改配置后的有效拾取，传播与无写死分支不可裁定，记录明确非基础设施故障。
interaction / 6.2	not_run	3	候选前置	各次 Tab 和 F 已送达，但候选从未打开背包界面，也没有成功新增库存；保持背包打开并拾取这一前提未成立，无法观察实时刷新，不能据此判刷新算法正确或错误。
interaction / 7.1	not_run	5	候选前置	保存的拾取模板为空，权威端无法准备两种有效物品，未生成配置文件或释放后续屏障；候选的有效拾取与界面前提缺失，两个玩家分别获得物品及提示隔离未被实际检验。
interaction / 7.2	not_run	3	候选前置	归属测试的四个变体因候选物品模板为空而停在配置准备，且生产背包界面始终未成立；未形成有效拾取后的反复开关与播报对照，零播报不能验证重复打开不增加次数。
interaction / 7.3	not_run	2	候选前置	网络运行未建立成功拾取与生产提示正例，部分归属变体还因空模板止于准备；无法在有效提示系统中比较成功和失败交互，始终没有提示不能证明失败时不会误报成功。
interaction / 8.1	not_run	3	混合原因	候选没有能力、选项或提示正例；同时销毁变体在同一驱动回调中排队 F 后、下一输入处理帧前销毁目标，未建立交互正在执行的时序。前置缺失与动作时序缺口并存，不能拆分该项权重。
interaction / 8.3	not_run	3	候选前置	两轮真实离开和返回保存地图已完成，且各轮 F/Tab 送达；但初始及重进后均无交互能力、选项和背包，没有已建立的交互回调或提示可比较，零事件不能证明不存在重复残留。
context-effects / 1.4	not_run	5	候选前置	六种参数的基准与变更共十二次运行均完成前置检查，但保存地图缺少 Concrete 物理地面，均在修改参数和触发动作前停止；交付场景不足阻断对照，参数语义本身仍未知。

任务 / 项目	原状态	权重	原因分类	说明
context-effects / 3.3	not_run	4	混合原因	生产效果未形成非空缓存；评测战斗入口又未生成合法敌人，替换夹具只重启控制器而未销毁旧角色。虽有局部销毁和五次旅行正例，完整生命周期与失效缓存增长仍缺覆盖，不能按权重拆因。
context-effects / 3.4	not_run	3	候选前置	默认表面网络场景已形成真实动作与通知，专服无输出，但客户端也无候选脚步输出；其余八组因保存地面缺失止于动作前。零客户端输出不能检验双重转发去重，尚非网络算法已证实失败。
context-effects / 6.3	not_run	4	评测缺口	移动、跳跃和武器弹药变化已观察成功，但评测的机器人入口未产生可受伤的敌对目标，正常战斗死亡及重生未发生；缺失的是该回归场景的有效动作覆盖，未证明场景效果实现破坏了死亡重生。
accolades / 1.5	not_run	4	评测缺口	缺档无替代/不重复、真实离场和新玩家独立计数均有正例；原观察器weak.IsValid在GC前已false，未测到对象实际回收，不能仅TObjectPtr/gc0认定泄漏，原整项记录可释放仍未验证。
accolades / 4.1	not_run	5	评测缺口	显示态替换已成立，但等待态安全地面/低请求、高Row取消及晚回调必要链没有形成；串行实现和未提供独立退出窗口不构成已确证的原项功能缺失。
accolades / 4.2	not_run	4	评测缺口	实际非空FIFO与GC存活有正例；受控逆序及两个实际候选callback身份/时序没有闭合。未用旧私有字段形状要求或必须并行加载的新条件判失败。

未验证原因及原始分支明细